

TMM / 多模型量化实验结果汇总

更新时间：2026-08-19 13:23（实验节点 CST）本文只纳入有日志、指标文件或 checkpoint 可追溯的结果；7Scenes 是当前主报告集。ETH3D 为当前 E1 adapter 口径，与论文/PDF 参考协议仍有差异，因此作为辅助结果，不据此单独作算法因果判断。

目录

- 1. 执行摘要
- 2. 统一评估协议
- 3. VGGT 统一主表
- 4. 跨基座模型与指定补充实验
- 5. 校准集与关键实现消融
- 6. TAPTQ 补偿结果与消融
- 7. 附录：Quant-only、PDF 与旧协议结果
- 8. H800 fused W8A8 与 W4A8 hybrid 部署
- 9. 结果与产物索引

1. 执行摘要

- 状态：长期 H800 lease Run 702478252 正常保留且不会释放；OpenD4RT 的 FP、W4A8 non-channel-wise、W4A8 channel-wise 已完成，8 张 GPU 当前 idle。VGGT-Omega 按用户要求暂缓。实时状态只以 doc/H800_LEASE_GPU_STATUS.md 为准。
- **VGGT** 精度：在 §3.1 所列 W4A8 主表方法中，SVDQuant aligned 的 7Scenes Acc 最低；TAPTQ 推荐 $\rho=0.1/\tau=0.007/r_{128}$ 的 NC 最高。全量消融中存在更高 NC 点，默认 r_{128} 是参数量与精度的折中，不是所有配置上的单指标全局最优。
- 新基座 **OpenD4RT**：7Scenes full18 的 FP 为 0.039151/0.049335/0.647854；channel-wise W4A8 为 0.039429/0.048970/0.645904，基本保持 FP；non-channel-wise W4A8 为 0.099541/0.182797/0.589010，明显退化。详见 §4.3。
- **QwT**：外部模型计划搜索 204 个组合，形成 202 条有效筛选结果；失败或跳过项不参与选优。DUSt3R 的门控 channel-wise QwT 在 full18 上有小幅收益，MASt3R 与 clean quant-only 相同；non-channel-wise + QwT 在 DUSt3R、MASt3R 上明显退化。Pi3 non-channel-wise + QwT 的 Acc/NC 退化而 Comp 改善，不推荐作为默认配置。
- 部署：H800 fused W8A8 已实现。低延迟 single 模式在 8-view 为 147.225 ms，同口径 BF16 为 149.506 ms，首次实现 '**1.015×**' 高于 **BF16**；full18 为 0.017546/0.032976/0.689514。精确 dual-scale 模式末层 cosine 0.999188，但 8-view 为 157.767 ms。此前 W4/A8-calibrated hybrid FP8/BF16 为 338.172 ms，并非原生 fused INT4×INT8。详见 §8。
- 实现审计：ERQ 补齐 qkv/fc1 two-part 后显著改善；SmoothQuant W4A8 以 $\alpha=0.3$ 最好。固定 4096-token 预算下，DTU20 未带来一致收益，部分指标改善、部分退化。旧含 QwT hooks 的 quant-only checkpoint 已排除，最终基线均采用 clean checkpoint + `--disable-qwt`。

2. 统一评估协议

项目	设置
主模型	VGGT-1B；另测 Pi3、DUST3R、MASt3R
评估器	E1 unified evaluator
输入分辨率	VGGT/Pi3：518；DUST3R/MASt3R：原生 512 预处理
7Scenes dense	18 个序列
ETH3D	13 个序列；当前 E1 adapter 辅助口径，尚未与论文/PDF 参考协议完全对齐
指标	Acc、Comp 越低越好；NC 越高越好；NC=(NC1+NC2)/2
数值格式	Mean / Median；仅有 Mean 时明确标注
默认校准	DTU_train_8，4096 tokens/layer
共同量化范围	VGGT aggregator 的 288 个 qkv/proj/fc1/fc2 Linear
TAPTQ 推荐参数	W4A8 ternary，non-channel-wise，rho=0.1，tau=0.007，rank=128

3. VGGT 统一主表

3.1 FP、W4A8/W4A4 与 TAPTQ

方法	配置 / 校准	7Scenes Acc	7Scenes Comp	7Scenes NC	ETH3D Acc（辅助）	ETH3D Comp（辅助）	ETH3D NC（辅助）	Run/状态
FP VGGT	FP	0.018530 / —	0.031756 / —	0.689451 / —	0.577090 / —	1.395115 / —	0.674190 / —	702478252 复核
RTN	W4A8，DTU8/4096	0.031663 / 0.012442	0.043327 / 0.015790	0.684913 / 0.786767	0.625811 / 0.490863	1.445871 / 0.635089	0.617507 / 0.683662	702260369
RepQ-ViT aligned	W4A8，DTU8/4096	0.087162 / 0.048589	0.193871 / 0.089153	0.637539 / 0.707285	0.800381 / 0.712105	2.771863 / 1.382796	0.562350 / 0.602174	702260369
ERQ official-core	W4A8，无 part，DTU8/4096	two-0.077527 / 0.040823	0.149162 / 0.062177	0.650189 / 0.725127	0.723984 / 0.594335	2.355848 / 1.167670	0.527638 / 0.542057	702327342
ERQ official	W4A8，two-part，DTU8/4096	0.033990 / 0.015783	0.036652 / 0.014709	0.683896 / 0.785659	0.713734 / 0.589299	1.591601 / 0.784456	0.597714 / 0.649529	702384692
GPTQ official-core	W4A8，DTU8/4096	0.030389 / 0.012739	0.034527 / 0.015208	0.686803 / 0.789693	0.662946 / 0.537580	1.665329 / 0.830651	0.620042 / 0.680215	702478252 复核
SmoothQuant	W4A8，alpha=0.3，DTU8/4096	0.0633681 / 0.013081	0.039848 / 0.013914	0.688261 / 0.791354	0.668833 / 0.578171	1.458123 / 0.657663	0.612052 / 0.667618	702478252
SmoothQuant	W4A8，alpha=0.5，DTU8/4096	0.0648089 / 0.023292	0.042848 / 0.016567	0.685119 / 0.782658	0.678356 / 0.562190	1.610918 / 0.763441	0.587523 / 0.640375	702478252
SmoothQuant	W4A8，alpha=0.7，DTU8/4096	0.0650478 / 0.022520	0.062766 / 0.019639	0.666574 / 0.760571	0.759747 / 0.570499	1.931017 / 0.910673	0.561042 / 0.598554	702478252
SVDQuant aligned	W4A8，rank32，DTU8/1024	0.017294 / 0.007471	0.031685 / 0.015404	0.690436 / 0.793734	0.628478 / 0.394715	1.558726 / 0.754157	0.658262 / 0.733969	702260369
RepQ-ViT aligned	W4A4，DTU8/4096	0.091156 / 0.057058	0.396727 / 0.294829	0.602914 / 0.656186	0.723635 / 0.619237	3.567328 / 2.110682	0.553392 / 0.583904	702260369
ERQ official	W4A4，DTU8/4096	0.099045 / 0.060697	0.272316 / 0.165301	0.628182 / 0.692219	0.736098 / 0.660518	3.680139 / 2.201514	0.505074 / 0.511692	702327342
SVDQuant aligned	W4A4，rank32，DTU8/1024	0.017930 / 0.008122	0.032902 / 0.015660	0.688462 / 0.790606	0.613718 / 0.514135	1.462092 / 0.803721	0.653075 / 0.727498	702260369
TAPTQ 推荐	W4A8 non-CW，rho=.1/tau=.007/r128	0.018886 / 0.008108	0.035867 / 0.014019	0.694326 / 0.798332	0.632187 / 0.420825	1.603074 / 0.645639	0.626990 / 0.697055	701579542
TAPTQ channel-wise	W4A8，rho=.01/tau=.005/r256	0.018566 / 0.007794	0.032607 / 0.015484	0.689016 / 0.791702	0.560725 / 0.411231	1.429107 / 0.711722	0.682015 / 0.780931	701579542
PTQ4ViT	W4A8，DTU8	0.034261 / 0.015201	0.054669 / 0.018971	0.687745 / 0.785875	0.742479 / 0.571736	1.775614 / 0.880433	0.586200 / 0.631445	702478252，已完成

GPTQ 原生为 weight-only；本表 A8 使用 ERQ 公平比较协议中的 RepQ 激活量化器。SVDQuant 为 DeepCompressor 对齐的 PyTorch 精度实现，不代表 fused INT4 吞吐。PTQ4ViT 与

TAPTQ ternary quant-only 的 7Scenes 指标在浮点误差内一致，说明两者当前可能共享等价量化路径；在完成 checkpoint/产物来源复核前，PTQ4ViT 仅作为实现对照，不据此宣称独立方法收益。

3.2 W6A6/W8A8 补充结果

方法	配置	7Scenes Acc	7Scenes Comp	7Scenes NC	ETH3D Acc (辅助)	ETH3D Comp (辅助)	ETH3D NC (辅助)	Run
RTN	W6A6, DTU8/4096	0.040839 / 0.017774	0.040299 / 0.015795	0.678765 / 0.776879	0.674932 / 0.507827	1.863510 / 0.922853	0.610155 / 0.668981	702478252
RepQ-ViT aligned	W6A6, DTU8/4096	0.042609 / 0.018503	0.046005 / 0.015631	0.680743 / 0.779978	0.653042 / 0.529370	1.547453 / 0.626688	0.590350 / 0.635572	702478252
ERQ official	W6A6, two-part, DTU8/4096	0.036203 / 0.016959	0.040491 / 0.015544	0.681859 / 0.782245	0.745798 / 0.631373	1.730803 / 0.860565	0.601874 / 0.662996	702478252
GPTQ official-core	W6A6, DTU8/4096	0.039548 / 0.016853	0.041233 / 0.015108	0.679349 / 0.777936	0.687522 / 0.541173	1.692481 / 0.816184	0.603864 / 0.663436	702478252
SmoothQuant	W6A6, alpha=0.5, DTU8/4096	0.0434905 / 0.017402	0.047122 / 0.018534	0.679549 / 0.778883	0.677828 / 0.524349	1.915498 / 0.999511	0.603820 / 0.660733	702478252
TAPTQ channel-wise	W6A6, rho=.01/tau=.005/r256	0.019946 / 0.008776	0.034856 / 0.015121	0.688285 / 0.789994	0.650349 / 0.546553	1.630045 / 0.828188	0.621792 / 0.681915	701579542
TAPTQ channel-wise	W8A8, rho=.01/tau=.005/r256	0.018563 / 0.007435	0.031442 / 0.015487	0.689497 / 0.792460	0.612714 / 0.518221	1.486071 / 0.834080	0.664152 / 0.739866	701579542

4. 跨基座模型与指定补充实验

以下表格统一报告 7Scenes full18 Mean；- 表示没有同口径可追溯结果。跨模型最终选择只在本节维护，避免与后文重复。

4.1 FP、clean quant-only 与 channel-wise QwT 最终选择

模型	方法	配置	Acc / Comp / NC	结论
VGGT	FP	518 输入	0.018530 / 0.031756 / 0.689451	FP 参考
Pi3	FP	518 输入	0.015044 / 0.022652 / 0.685400	FP 参考
DUST3R	FP	原生 512	0.019343 / 0.029319 / 0.680308	FP 参考
MASt3R	FP	原生 512	0.025488 / 0.031090 / 0.665829	FP 参考
OpenD4RT	FP	32CLIP checkpoint, 原生 256	0.039151 / 0.049335 / 0.647854	FP 参考
OpenD4RT	non-channel-wise quant-only	W4A8 ternary, DTU8	0.099541 / 0.182797 / 0.589010	明显退化，不推荐
OpenD4RT	channel-wise quant-only	W4A8 ternary, DTU8	0.039429 / 0.048970 / 0.645904	基本保持 FP，推荐量化配置
DUST3R	channel-wise clean quant-only	W4A8, 224 校准/512 评估	0.024119 / 0.027904 / 0.673588	最终基线
DUST3R	channel-wise QwT best	rho=.001/tau=.007/fit $\leq$.6/r16	0.023192 / 0.027874 / 0.674361	三项均略优于基线，推荐
DUST3R	channel-wise QwT alternate	rho=.01/tau=.003/fit $\leq$.6/r16	0.024533 / 0.027305 / 0.673123	Comp 最优备选
MASt3R	channel-wise clean quant-only	W4A8, 224 校准/512 评估	0.032244 / 0.028564 / 0.654313	最终推荐
MASt3R	channel-wise QwT best	rho=.01/tau=.01/fit $\leq$.2/r16	0.032244 / 0.028564 / 0.654313	与 clean 基线相同
MASt3R	channel-wise QwT alternate	rho=.001/tau=.003/fit $\leq$.4/r16	0.032244 / 0.028564 / 0.654313	与 clean 基线相同

4.2 用户指定四项实验归档

下表产物路径均相对 `/mnt/cephfs/pansicheng/tmm-results/`；完整配置和绝对路径同步记录在 `doc/tmm_test_manifest.json`。

模型	CW	QwT	配置	Acc / Comp / NC	结论	产物
VGGT	Yes	No	W4A8 quant-only	0.017626 / 0.031211 / 0.691679	接近 FP，四项中最稳定	eval/ vggt_channelwise_quant_only/ tre_diff/all_metrics.csv
Pi3	No	Yes	$\rho=.1/\tau=.007/\text{fit}\leq .8/r16$	0.037403 / 0.014163 / 0.503651	Comp 改善，但 Acc/NC 明显退化，不推荐	eval/ pi3_noncw_qwt/ all_metrics.csv
DUST3R	No	Yes	$\rho=.1/\tau=.007/\text{fit}\leq .8/r16$	0.062016 / 0.054772 / 0.646184	明显差于 channel-wise safe QwT	eval/ dust3r_noncw_qwt/ _all_samples.json
MASt3R	No	Yes	$\rho=.1/\tau=.007/\text{fit}\leq .8/r16$	0.042619 / 0.743426 / 0.499973	Comp/NC 严重退化，不推荐	eval/ mast3r_noncw_qwt/ _all_samples.json

当前对照支持的经验结论：channel-wise quant-only 在 VGGT 上接近 FP；DUST3R 的门控 channel-wise QwT 有小幅收益，MASt3R 则没有可见收益。non-channel-wise + QwT 同时改变了量化粒度和补偿方式，缺少同口径 non-channel-wise quant-only 控制，因此只能判定该组合不稳定，不能把退化单独归因于 QwT。

4.3 OpenD4RT 新增基座

OpenD4RT 使用公开 32CLIP 训练 checkpoint，量化范围为 40 个 encoder block 的 160 个投影与 8 个 decoder block 的 48 个投影，共 208 个显式 Linear。校准使用冻结的 DTU8 seq-id-map，实际遍历 8 个 scan、每个 10 帧，共 80 张图像；日志中的 calibration size 32 只是旧元数据，并未截断校准迭代器。

配置	Acc Mean / Median	Comp Mean / Median	NC Mean / Median
FP	0.039151 / 0.015880	0.049335 / 0.018543	0.647854 / 0.729544
W4A8 non-CW	0.099541 / 0.063859	0.182797 / 0.103827	0.589010 / 0.636253
W4A8 channel-wise	0.039429 / 0.016178	0.048970 / 0.018367	0.645904 / 0.726407

相对 FP，channel-wise W4A8 的 Acc 仅增加 0.71%，Comp 降低 0.74%，NC 降低 0.30%；non-channel-wise 明显退化。因此默认采用 channel-wise W4A8。non-CW checkpoint 为 4,650,149,482 bytes，SHA256 8af9f6828e95d80381baf343c7cc825e856be31f4749e38ce10dcb4442feecf9；CW checkpoint 为 4,652,604,229 bytes，SHA256 0860090629b3187ebb7f22984089324e629e4a365ed66ba5c2c539bf820cf4fd。

4.4 外部 QwT 实现审计与搜索规模

旧 external QwT 没有与 VGGT 定义对齐：没有 $\rho/\text{tail_ratio}$ ；直接复用 $\tau=.007$ 导致 120/120 分支入选；逐分支即时安装 hook 使后续 capture 被污染；低秩截断后未重算 bias，也缺少 fit_error 门控。现已修复为 VGGT 同定义 top- ρ TRE、截断后重算 bias、全部 capture 后统一安装 hook，并以 fit_error 拒绝有害修正。

层级	模型	参数矩阵	计划组合数
rank16 初筛	DUST3R / MASt3R	$\rho=.001/.01/.1$ ； $\tau=.003/.007/.02$ ； $\text{fit}\leq .8$	24
rank16 密集门控	DUST3R / MASt3R	各 ρ 上 $\tau=.001/.003/.005/.007/.01/.02/.05$ ； $\text{fit}\leq .2/.4/.6$	144

层级	模型	参数矩阵	计划组合数
高 rank	DUS3R / MAs3R	rank=32/64/128 ; rho=.1 ; tau=.005/.007 ; fit $\leq$.4/.6/.8	36

合计计划 204 个组合，其中新增/扩展队列为 180 个；最终形成 DUS3R 100 条、MAs3R 102 条有效结果，共 202 条。失败或跳过配置不进入选优；已明确记录的早期 DUS3R fit $\leq$.8 诊断配置因 OpenCV SQnPn 失败，后续 fit $\leq$.6 选优配置已成功完成 full18。

5. 校准集与关键实现消融

5.1 ERQ two-part 与 DTU8/DTU20

方法	位宽	校准集	two-part	7Scenes Acc / Comp / NC	ETH3D Acc / Comp / NC (辅助)
ERQ	W4A8	DTU8/4096	No	0.077527 / 0.149162 / 0.650189	0.723984 / 2.355848 / 0.527638
ERQ	W4A8	DTU8/4096	Yes	0.033990 / 0.036652 / 0.683896	0.713734 / 1.591601 / 0.597714
ERQ	W6A6	DTU8/4096	Yes	0.036203 / 0.040491 / 0.681859	0.745798 / 1.730803 / 0.601874
ERQ	W4A8	DTU20/4096	Yes	0.088206 / 0.146000 / 0.646577	0.735495 / 2.665761 / 0.543135
ERQ	W6A6	DTU20/4096	Yes	0.078380 / 0.125551 / 0.652625	0.729353 / 2.384169 / 0.536392

ERQ 固定官方 commit 2f5b4cee... , Aqr/Wqr、Rounding Refinement top-k=1/T=100、coe=20000 (ridge=2000)、row batch=500、4096 tokens ; two-part 仅用于 qkv/fc1。

5.2 GPTQ 的 DTU8/DTU20 对照

位宽	校准集	7Scenes Acc / Comp / NC	ETH3D Acc / Comp / NC (辅助)
W4A8	DTU8/4096	0.030389 / 0.034527 / 0.686803	0.662946 / 1.665329 / 0.620042
W4A8	DTU20/4096	0.041455 / 0.046168 / 0.686904	0.895817 / 1.821033 / 0.605249
W6A6	DTU8/4096	0.039548 / 0.041233 / 0.679349	0.687522 / 1.692481 / 0.603864
W6A6	DTU20/4096	0.059999 / 0.054133 / 0.668440	0.667404 / 1.541667 / 0.583569

固定总 token 数时，DTU20 把每个场景可保留的 token 降到约 205，而 DTU8 每场景约 512；当前结果说明增加场景数但降低单场景覆盖密度并不稳定。

6. TAPTQ 补偿结果与消融

6.1 五个 checkpoint : rho=0.1, tau=0.007, rank=16

Run 701491027，均为 module-level QwT。单元格格式为 Acc / Comp / NC，且每项为 Mean / Median。

Setting	7Scenes Acc / Comp / NC	ETH3D Acc / Comp / NC (辅助)
W4A8 ternary	0.025325/0.010828 · 0.045779/0.016523 · 0.691264/0.792966	0.737394/0.522143 · 1.871054/0.794437 · 0.598173/0.643395
W4A8 exhaustive	0.025559/0.010913 · 0.044980/0.016859 · 0.691035/0.792994	0.703874/0.571900 · 1.714639/0.846824 · 0.603023/0.656432
W4A8 channel-wise	0.018475/0.007765 · 0.032060/0.015267 · 0.690933/0.794041	0.579910/0.482506 · 1.351510/0.707765 · 0.666858/0.756049
W6A6 ternary	0.020278/0.008620 · 0.034891/0.014573 · 0.690415/0.793453	0.631006/0.512185 · 1.446393/0.687413 · 0.633204/0.702324
W8A8 ternary	0.018175/0.007420 · 0.031062/0.015221 · 0.689673/0.792565	0.614368/0.524083 · 1.472902/0.851219 · 0.664082/0.744015

6.2 rho、tau、rank 消融合并表

均为 W4A8 ternary non-channel-wise , 主评估集为 7Scenes dense。单元格格式为 Mean / Median。

消融	取值	固定参数	Acc	Comp	NC
rho	0.001	tau=.007, r16	0.031290 / 0.013556	0.054002 / 0.020365	0.686838 / 0.785589
rho	0.005	tau=.007, r16	0.032472 / 0.013279	0.058019 / 0.020586	0.685139 / 0.784574
rho	0.01	tau=.007, r16	0.028793 / 0.011803	0.051019 / 0.018225	0.688277 / 0.788356
rho	0.02	tau=.007, r16	0.028101 / 0.012400	0.049177 / 0.018192	0.688762 / 0.789268
rho	0.05	tau=.007, r16	0.026571 / 0.011379	0.045859 / 0.015848	0.689650 / 0.790928
rho	0.1	tau=.007, r16	0.025325 / 0.010828	0.045779 / 0.016523	0.691264 / 0.792966
rho	0.5	tau=.007, r16	0.026750 / 0.011279	0.043143 / 0.015477	0.687830 / 0.788687
rho	1.0	tau=.007, r16	0.028978 / 0.012071	0.044269 / 0.015732	0.687913 / 0.788951
tau	0 (无效, 实际回退为 .007)	rho=.1, r16	0.025325 / 0.010828	0.045779 / 0.016523	0.691264 / 0.792966
tau	0.001	rho=.1, r16	0.027780 / 0.011349	0.045384 / 0.015336	0.687713 / 0.789177
tau	0.003	rho=.1, r16	0.029114 / 0.012179	0.045643 / 0.015312	0.686996 / 0.787027
tau	0.005	rho=.1, r16	0.024321 / 0.010059	0.041814 / 0.014438	0.689287 / 0.791060
tau	0.007	rho=.1, r16	0.025325 / 0.010828	0.045779 / 0.016523	0.691264 / 0.792966
tau	0.01	rho=.1, r16	0.027683 / 0.011701	0.053068 / 0.019010	0.687786 / 0.787751
tau	0.02	rho=.1, r16	0.029778 / 0.012919	0.052901 / 0.019817	0.688148 / 0.787293
tau	0.05	rho=.1, r16	0.029030 / 0.012653	0.051640 / 0.019381	0.688465 / 0.788458
rank	8	rho=.1, tau=.007	0.027066 / 0.011533	0.045646 / 0.016145	0.690162 / 0.791503
rank	16	rho=.1, tau=.007	0.025325 / 0.010828	0.045779 / 0.016523	0.691264 / 0.792966
rank	32	rho=.1, tau=.007	0.020863 / 0.008915	0.039108 / 0.015731	0.692756 / 0.795568
rank	64	rho=.1, tau=.007	0.019590 / 0.008517	0.037044 / 0.014933	0.692338 / 0.795237
rank	128	rho=.1, tau=.007	0.018886 / 0.008108	0.035867 / 0.014019	0.694326 / 0.798332
rank	256	rho=.1, tau=.007	0.018472 / 0.008117	0.033707 / 0.014021	0.694432 / 0.798279

ETH3D rank 辅助结果 : r16=0.737394/1.871054/0.598173 , r32=0.696210/1.681153/0.604388 (Mean)。

6.3 Channel-wise rho、tau、rank 消融合并表

均为 VGGT W4A8 ternary **channel-wise**，DTU8 校准，主评估集为 7Scenes dense。单元格格式为 Mean / Median；数据来自 vgg_t_channelwise_ablation 的逐配置 all_metrics.csv，不是 §6.2 的 non-channel-wise sweep。

消融	取值	固定参数	Acc	Comp	NC
rho	0.001	tau=.005, r128	0.018026 / 0.007687	0.031896 / 0.015213	0.691003 / 0.793865
rho	0.005	tau=.005, r128	0.018394 / 0.007722	0.032502 / 0.015865	0.690571 / 0.793775
rho	0.01	tau=.005, r128	0.018026 / 0.007687	0.031896 / 0.015213	0.691003 / 0.793865
rho	0.02	tau=.005, r128	0.018026 / 0.007687	0.031896 / 0.015213	0.691003 / 0.793865
rho	0.05	tau=.005, r128	0.018348 / 0.007925	0.032280 / 0.015439	0.689540 / 0.792480
rho	0.1	tau=.005, r128	0.018364 / 0.007913	0.032123 / 0.015350	0.690079 / 0.792663
rho	0.5	tau=.005, r128	0.018394 / 0.007722	0.032502 / 0.015865	0.690571 / 0.793775
rho	1.0	tau=.005, r128	0.018401 / 0.007965	0.032824 / 0.016106	0.690143 / 0.793065
tau	0（无效，实际回退为 .007）	rho=.01, r128	0.019100 / 0.008028	0.032920 / 0.015457	0.688014 / 0.790337
tau	0.001	rho=.01, r128	0.018053 / 0.007652	0.032343 / 0.015619	0.690476 / 0.793487
tau	0.003	rho=.01, r128	0.018288 / 0.007696	0.032210 / 0.015435	0.689748 / 0.792014
tau	0.005	rho=.01, r128	0.018026 / 0.007687	0.031896 / 0.015213	0.691003 / 0.793865
tau	0.007	rho=.01, r128	0.019100 / 0.008028	0.032920 / 0.015457	0.688014 / 0.790337
tau	0.01	rho=.01, r128	0.018031 / 0.007699	0.032167 / 0.015132	0.690221 / 0.793132
tau	0.02	rho=.01, r128	0.017528 / 0.007738	0.031104 / 0.014808	0.691759 / 0.795235
tau	0.05	rho=.01, r128	0.017630 / 0.007700	0.031155 / 0.014870	0.691688 / 0.795073
rank	8	rho=.01, tau=.005	0.018333 / 0.007611	0.031925 / 0.015087	0.690835 / 0.793852
rank	16	rho=.01, tau=.005	0.018276 / 0.007680	0.032410 / 0.015222	0.690000 / 0.793117
rank	32	rho=.01, tau=.005	0.018067 / 0.007669	0.031918 / 0.015356	0.691678 / 0.795242
rank	64	rho=.01, tau=.005	0.018442 / 0.007844	0.031989 / 0.015456	0.690155 / 0.792975
rank	128	rho=.01, tau=.005	0.018026 / 0.007687	0.031896 / 0.015213	0.691003 / 0.793865
rank	256	rho=.01, tau=.005	0.018566 / 0.007794	0.032607 / 0.015484	0.689016 / 0.791702

已完成的额外交叉点：rho=.1, tau=.007, r128 为 Acc 0.018261/0.007564、Comp 0.032282/0.015245、NC 0.690139/0.792842；§6.1 的 rho=.1, tau=.007, r16 为 0.018475/0.007765、0.032060/0.015267、0.690933/0.794041。由于固定参数不同，这两个点不混入上面的单变量最优比较。

12 项缺失配置现已全部完成并回填。固定 tau=.005, r128 时，rho=.001/.01/.02 的结果相同；固定 rho=.01, tau=.005 时，rank128 的 Acc/Comp 最好，rank32 的 NC 最好。固定 rho=.01, rank128 时，当前 tau=.02 在有效点中对 Acc/Comp/NC 三项综合最好。历史 tau=0 命令因零值回退实际执行为 .007，仅保留作溯源，不参与消融结论。

6.4 跨 setting 组合筛选

Run 701546763，Mean 指标。

Setting	CW	rho/tau/rank	7Scenes Acc / Comp / NC	ETH3D Acc / Comp / NC (辅助)
W4A8 ternary	No	.1/.005/256	0.018990 / 0.034746 / 0.693951	0.658013 / 1.587040 / 0.618117
W4A8 ternary	No	.01/.005/256	0.020057 / 0.031452 / 0.692546	0.720945 / 1.784419 / 0.631503
W4A8 ternary	No	.05/.005/128	0.019426 / 0.036389 / 0.694892	0.838353 / 1.944112 / 0.619188
W4A8 exhaustive	No	.01/.005/256	0.020061 / 0.036617 / 0.694042	0.772398 / 1.681983 / 0.632591
W4A8 channel-wise	Yes	.01/.005/256	0.018566 / 0.032607 / 0.689016	0.560725 / 1.429107 / 0.682015
W6A6 ternary	No	.01/.005/256	0.018232 / 0.032846 / 0.691639	0.639463 / 1.602481 / 0.652772
W8A8 ternary	No	.01/.005/256	0.018283 / 0.031144 / 0.689938	0.609459 / 1.485683 / 0.665736
W4A8 ternary	No	.1/.007/128	0.018886 / 0.035867 / 0.694326	0.632187 / 1.603074 / 0.626990

综合性能与参数量，默认仍采用 rho=0.1，tau=0.007，rank=128；若只追求 7Scenes 上界，可用 rank=256。

6.5 W4A8 补偿比例与模块选择消融（新协议）

本轮冻结结果使用 VGGT W4A8、DTU_train_8 校准、7Scenes dense full18，固定 rho=.1，rank=128，在 144 个候选模块上比较五档预算；62/144 是默认 tau=.007 实际选出的模块数。随机选择固定 τ 的 ρ 均值。

预算	TRE	MSE	Hessian	Random
24/144	0.025874/0.044597/0.688276	0.030371/0.045536/0.687632	0.030503/0.046976/0.685933	0.030941/0.046923/0.688319
48/144	0.021498/0.038211/0.692796	0.022470/0.038236/0.691454	0.024763/0.040115/0.689811	0.022949/0.039355/0.689175
62/144	0.019822/0.036430/0.695265	0.022227/0.037820/0.690148	0.020257/0.035947/0.692438	0.022525/0.040430/0.691274
72/144	0.019895/0.035862/0.694169	0.020140/0.037739/0.692988	0.019011/0.036116/0.694760	0.021396/0.038489/0.691965
96/144	0.019795/0.034718/0.694900	0.019551/0.036839/0.692821	0.020036/0.036529/0.692752	0.024370/0.042894/0.689881

结论边界：TRE 在默认 62/144 点取得最佳 NC，在 96/144 点取得最佳 Comp；72/144 的最低 Acc 来自 Hessian，96/144 的最低 Acc 来自 MSE。因此应将结果描述为匹配补偿预算下的精度 ρ 几何权衡，不宣称 TRE 在所有预算和指标上绝对最优。

7. 附录：Quant-only、PDF 与旧协议结果

7.1 统一评估器下的 quant-only 历史结果（Mean）

配置	7Scenes Acc / Comp / NC
TAPTQ W4A8 ternary	0.034261 / 0.054669 / 0.687745
TAPTQ W4A8 exhaustive	0.031122 / 0.049532 / 0.690451
TAPTQ W4A8 channel-wise	0.017626 / 0.031211 / 0.691679
TAPTQ W6A6 ternary	0.020507 / 0.035523 / 0.691768
TAPTQ W8A8 ternary	0.018129 / 0.031015 / 0.689912

7.2 PDF 中的 VGGT Ours 参考

配置	PDF 7Scenes Acc / Comp / NC	PDF ETH3D Acc / Comp / NC	当前可追溯对应结果
W4A8 Ours	0.028/0.044/0.687	0.492/0.677/0.761	r16 : 0.025325/0.045779/0.691264 ; ETH3D 0.737394/1.871054/0.598173
W6A6 Ours	0.021/0.037/0.690	0.334/0.406/0.813	r16 : 0.020278/0.034891/0.690415 ; ETH3D 0.631006/1.446393/0.633204
W4A8 channel-wise	0.018/0.032/0.688	—	0.018566/0.032607/0.689016 ; ETH3D 0.560725/1.429107/0.682015

ETH3D 当前 FP 与 PDF 也存在明显差距，因此不能把量化行差异单独归因于算法；还需对齐 PDF 的预处理、帧采样、checkpoint 与 evaluator。

7.3 不进入主表的旧/异协议结果（Mean）

方法	7Scenes Acc / Comp / NC	ETH3D Acc / Comp / NC	原因
QuantVGGT W4A8	0.020489 / 0.033833 / 0.676142	—	upstream evaluator
QuantVGGT W8A8	0.020497 / 0.033838 / 0.676140	—	upstream evaluator
RTN-style W4A8	0.020496 / 0.033840 / 0.676275	—	upstream evaluator
早期 RTN adapter W4A8	0.034997 / 0.057019 / 0.681497	0.674124 / 1.803128 / 0.603189	已被 aligned 实现替代
早期 RepQ adapter W4A8	0.114202 / 0.269601 / 0.613569	0.854631 / 3.267392 / 0.527036	已被 aligned 实现替代
早期 ERQ adapter W4A8	0.066906 / 0.607316 / 0.577133	0.717029 / 4.477670 / 0.527616	遗漏 two-part
早期 SVDQuant-style W4A8 r128	0.051505 / 0.057741 / 0.685049	0.704531 / 1.653232 / 0.583574	已被 DeepCompressor aligned 替代
早期 SVDQuant-style W4A4 r32	0.100695 / 0.279415 / 0.625871	0.774879 / 3.532489 / 0.521273	已被 aligned 实现替代

8. H800 fused W8A8 与 W4A8 hybrid 部署

8.1 fused W8A8 实现

W8A8 部署使用 w8a8_ternary.pt 的 288 个 quant-only Linear。Triton 3.1.0 后端将 activation A8 量化作为 producer kernel；对 72 个 FC2，exact GELU 与 A8 量化合并；INT8 Tensor Core GEMM 的 epilogue 融合 INT32 反量化、per-output weight scale、bias 和 BF16 cast。推理图不包含 QwT/LoRA 额外分支。

当前保留两种 Post-GELU 模式：

- single：单个对称 INT8 GEMM，舍弃独立负尾 scale；延迟最低。
- dual：同一 Triton kernel 内计算正/负两个 INT8 accumulator，保留原 TAPTQ 双 scale 语义；精度更高但计算量更大。

正式协议：H800、VGGT-1B aggregator、batch=1、518×518、CUDA Graph、5 warmup、20 timed、CUDA events。BF16 均单独加载并使用相同 graph 协议复测。

Views	BF16 latency	fused W8A8 single	vs BF16	W8A8 throughput
1	21.483 ms	21.506 ms	0.999×	46.499 views/s
2	35.453 ms	34.259 ms	1.035×	58.380 views/s
4	67.667 ms	66.850 ms	1.012×	59.835 views/s

Views	BF16 latency	fused W8A8 single	vs BF16	W8A8 throughput
8	149.506 ms	147.225 ms	1.015×	54.339 views/s

8-view single 模式运行时模型为 2,305,939,388 bytes，约为 FP32 的 **45.88%**；CUDA Graph replay peak allocated 为 3,399,778,304 bytes（约 3.166 GiB）。相对 BF16 的收益目前较小但已经为正，说明 fused INT8 路径已经跨过了 PyTorch primitive 版本的开销拐点。

数值与几何复核：

模式	末层 cosine / relative L2	7Scenes Acc Mean/Med	Comp Mean/Med	NC Mean/Med
single	0.991220 / 0.135891	0.017546 / 0.008017	0.032976 / 0.015591	0.689514 / 0.792069
dual	0.999188 / 0.044705	0.018333 / 0.007366	0.030944 / 0.014997	0.687220 / 0.789228

single 的 full18 几何结果仍接近 W8A8 fake-quant 与 FP，但逐 stage 误差明显高于 dual。默认低延迟部署采用 single；精度敏感场景采用 dual，其 8-view latency 为 157.767 ms，相对 BF16 为 0.948×

产物：/mnt/cephfs/pansicheng/tmm-results/deploy/vggt_w8a8_triton/；代码：Pi3-evaluation/deployment/w8a8_triton_deploy.py、validate_w8a8_triton.py、evaluate.py

8.2 W4/A8-calibrated hybrid FP8/BF16 回顾与 B200 对齐

准确命名：**H800 W4/A8-calibrated hybrid FP8/BF16 prototype**。它使用 packed INT4 artifact 和 TAPTQ W4/A8 校准网格，但不是原生 fused INT4×INT8 kernel。

8.2.1 论文数据口径

论文和 rebuttal 实际使用的是 **NVIDIA B200**，不是 B300。口径为 VGGT-1B **aggregator forward**、batch=1、8 views、每帧 518×518、5 次 warmup、25 次 CUDA-event timed runs。论文表中只有 FP32、W8A8 和 W8-Abf16，没有 W4A8 部署行：

B200 配置	Latency	Speedup	Weight	Peak
FP32	401 ms	1.00×	5.0 GB	9.9 GB
W8A8 static + compile	74 ms	5.42×	1.7 GB	4.1 GB
W8-Abf16 + compile	81 ms	4.95×	1.4 GB	3.8 GB

B200 表使用编译后的 W8 后端，不能与 H800 上的 W4A8 prototype 直接作硬件等价比较。论文输入描述中误排的 85,182-pixel frames 已修正为 8 × 518 × 518 frames。

8.2.2 H800 W4A8 优化实现与公平对照

H800 路径采用 packed signed INT4 artifact。由于 PyTorch 2.5 没有原生 fused INT4×INT8 API，当前最佳后端保持 TAPTQ 的 W4/A8 校准网格，但用 Hopper E4M3 FP8 承载量化整数执行 216 个普通 Linear；72 个 dual-scale Post-GELU FC2 使用单次 BF16 Tensor Core GEMM。其余 aggregator 算子使用 BF16，任务头保留 FP32；固定 shape 使用 CUDA Graph。INT8 _int_mm 后端仍保留为精确整数参考。

正式协议：H800、VGGT-1B aggregator、batch=1、518×518、5 warmup、20 timed、CUDA events。除论文对齐的 FP32 基线外，额外加入相同 CUDA Graph 的 BF16 非量化基线，用于分离“量化后端收益”和“单纯降 dtype 收益”。显存为 graph 准备完成后的 replay 峰值，不含首次 capture/compile 瞬时内存。

Views	FP32 latency	BF16 latency	W4A8-FP8 latency	vs FP32	vs BF16	W4A8 throughput	FP32 / BF16 / W4A8 peak
1	98.531 ms	21.460 ms	44.239 ms	2.227 ×	0.485×	22.604 views/s	4.998 / 2.565 / 2.681 GiB
2	194.968 ms	35.403 ms	79.896 ms	2.440 ×	0.443×	25.033 views/s	5.253 / 2.695 / 2.808 GiB
4	412.582 ms	68.166 ms	168.058 ms	2.455 ×	0.406×	23.801 views/s	5.762 / 2.956 / 3.063 GiB
8	925.427 ms	148.751 ms	338.172 ms	2.737 ×	0.440×	23.657 views/s	6.780 / 3.477 / 3.572 GiB

优化演进（8 views）：初版 hybrid 为 942.18 ms / 1.051×，稳定 INT8+BF16+CUDA Graph 为 487.32 ms / 1.898×，最终 FP8 Tensor Core 后端为 338.17 ms / 2.737×。最终版本相对初版 latency 降低 **64.1%**，相对稳定 INT8 版再降低 **30.6%**。

但公平的 BF16 对照只有 148.75 ms：当前 W4A8-FP8 仍比 BF16 慢约 2.27×（即 0.440×）。因此 **2.737**× 只能表述为相对 **FP32** 的端到端收益，不能归因于纯 **W4A8 kernel**。剩余瓶颈是每层独立的 activation round/clamp/cast、输出反量化与 per-channel scale，尚未融合到 GEMM；要接近论文 B200 的 5.42×，需要 CUTLASS/Triton/TensorRT 原生 fused W4A8 kernel，而不是继续叠加 PyTorch eager primitive。

存储方面，packed artifact 为 458,648,854 bytes（约 437.4 MiB）；完整运行时模型约为 FP32 的 **51.88%**。FP8 路径逐 stage 验证末层 cosine 为 0.998389、relative L2 为 0.06020，通过默认质量阈值。

最终 FP8 部署已完成 7Scenes E1 full18 几何复核：

部署配置	Acc Mean / Median	Comp Mean / Median	NC Mean / Median
stable INT8/BF16 + FP32 heads	0.017404 / 0.007699	0.031026 / 0.014696	0.690020 / 0.792752
216 FP8 GEMMs + 72 BF16 FC2 + BF16 non-Linear ops + FP32 heads	0.017337 / 0.007660	0.030804 / 0.014446	0.689845 / 0.792377

两条实际部署结果均与 channel-wise fake-quant quant-only 的 0.017626/0.031211/0.691679（Mean）接近，未出现几何精度崩溃。FP8 相对稳定 INT8 的 Acc/Comp 略优、NC 略低，差异较小。

原始性能产物：/mnt/cephfs/pansicheng/tmm-results/deploy/vggt_w4a8_int8/fp8_graph_b1v{1,2,4,8}.json；几何产物：/mnt/cephfs/pansicheng/tmm-results/eval/vggt_w4a8_fp8_deploy/tre_diff/all_metrics.csv；代码：Pi3-evaluation/deployment/w4a8_int8_deploy.py。

9. 结果与产物索引

9.1 台账与 Checkpoint

- 结构化测试台账：doc/tmm_test_manifest.json
- 模型台账：doc/tmm_model_manifest.json
- 实时 GPU 台账：doc/H800_LEASE_GPU_STATUS.md
- Checkpoint：/mnt/cephfs/pansicheng/tmm-results/checkpoints/
- 日志：/mnt/cephfs/pansicheng/tmm-results/logs/

9.2 VGGT 主表与消融

- 官方对齐 baseline：/mnt/cephfs/pansicheng/tmm-results/eval/vggt_official_aligned/

- ERQ two-part : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_erq_two_part/
- GPTQ DTU8/DTU20 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_gptq_dtu8/、 /mnt/cephfs/pansicheng/tmm-results/eval/vggt_gptq_dtu20/
- SmoothQuant : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_smoothquant/
- TAPTQ 补偿 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_taptq_compensated_rho01_tau0007_r16/
- non-channel-wise 消融 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_ablation/
- channel-wise 完整消融 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_channelwise_ablation/
- 跨 setting 筛选 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_combo_selection/

9.3 跨模型与指定实验

- 四项指定实验根目录 : /mnt/cephfs/pansicheng/tmm-results/eval/requested4/
- DUS3R/MAS3R external QwT full18 : /mnt/cephfs/pansicheng/tmm-results/eval/full18/
- OpenD4RT FP/CW/non-CW : /mnt/cephfs/pansicheng/tmm-results/eval/d4rt_opend4rt_{fp,w4a8_cw,w4a8_noncw}/
- OpenD4RT W4A8 checkpoint : /mnt/cephfs/pansicheng/tmm-results/checkpoints/d4rt_opend4rt_w4a8_{cw,noncw}.pt
- OpenD4RT 日志 : /mnt/cephfs/pansicheng/tmm-results/logs/d4rt_opend4rt_*.log
- external QwT 快筛脚本 : run-external-qwt-rho-tau.sh、 run-external-qwt-filter-sweep.sh、 run-external-qwt-rank-sweep.sh ; 日志统一从 /mnt/cephfs/pansicheng/tmm-results/logs/ 按任务名检索

9.4 H800 部署

- packed INT4 artifact : /mnt/cephfs/pansicheng/tmm-results/deploy/vggt_w4a8_int8/w4a8_packed_v2.pt
- FP8 性能矩阵 : /mnt/cephfs/pansicheng/tmm-results/deploy/vggt_w4a8_int8/fp8_graph_b1v{1,2,4,8}.json
- FP8 数值验证 : /mnt/cephfs/pansicheng/tmm-results/deploy/vggt_w4a8_int8/fp8_validation.json
- stable INT8/BF16 几何结果 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_w4a8_deploy_optimized/tre_diff/all_metrics.csv
- FP8/BF16 hybrid 几何结果 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_w4a8_fp8_deploy/tre_diff/all_metrics.csv
- fused W8A8 artifact : /mnt/cephfs/pansicheng/tmm-results/deploy/vggt_w8a8_triton/w8a8_int8_v2.pt (与已评估 v1 的 288 层权重和 scale 逐项一致)
- fused W8A8 性能矩阵 : /mnt/cephfs/pansicheng/tmm-results/deploy/vggt_w8a8_triton/*graph_b1v*.json
- fused W8A8 single/dual 几何结果 : /mnt/cephfs/pansicheng/tmm-results/eval/vggt_w8a8_triton_{single,dual}/tre_diff/all_metrics.csv
- 部署代码 : Pi3-evaluation/deployment/